

# Analytics e Inteligência Artificial

Tema da aula  
**Séries Temporais**



## BUSINESS SCHOOL

Graduação, pós-graduação,  
MBA, Pós- MBA, Mestrado  
Profissional, Curso In  
Company e EAD



## CONSULTING

Consultoria personalizada  
que oferece soluções  
baseada em seu problema  
de negócio



## RESEARCH

Atualização dos  
conhecimentos e do material  
didático oferecidos nas  
atividades de ensino



Líder em Educação Executiva, referência de ensino nos cursos de graduação, pós-graduação e MBA, tendo excelência nos programas de educação. Uma das principais **escolas de negócio do mundo**, possuindo convênios internacionais com Universidades nos EUA, Europa e Ásia. +8.000 **projetos de consultorias** em organizações públicas e privadas.



Único curso de graduação em administração a receber as notas máximas



A primeira escola brasileira a ser finalista da maior competição de MBA do mundo



Única Business School brasileira a figurar no ranking LATAM



Signatária do Pacto Global da ONU



Membro fundador da ANAMBA - Associação Nacional MBAs



Credenciada pela AMBA - Association of MBAs



Credenciada ao Executive MBA Council



Filiada a AACSB - Association to Advance Collegiate Schools of Business



Filiada a EFMD - European Foundation for Management Development



Referência em cursos de MBA nas principais mídias de circulação

O **Laboratório de Análise de Dados** – LABDATA é um Centro de Excelência que atua nas áreas de ensino, pesquisa e consultoria em análise de informação utilizando técnicas de **Big Data, Analytics** e **Inteligência Artificial**.



O LABDATA é um dos pioneiros no lançamento dos cursos de *Big Data* e *Analytics* no Brasil

Os diretores foram professores de grandes especialistas do mercado

+10 anos de atuação

+1000 alunos formados



## Docentes

- Sólida formação acadêmica: doutores e mestres em sua maioria
- Larga experiência de mercado na resolução de *cases*
- Participação em Congressos Nacionais e Internacionais
- Professor assistente que acompanha o aluno durante todo o curso

## Estrutura

- 100% das aulas realizadas em laboratórios
- Computadores para uso individual durante as aulas
- 5 laboratórios de alta qualidade (investimento +R\$2MM)
- 2 Unidades próximas a estação de metrô (com estacionamento)



Profª Dra.  
**Alessandra Montini**

Diretora do LABDATA-FIA, apaixonada por dados e pela arte de lecionar. Têm muito orgulho de ter criado na FIA cinco laboratórios para as aulas de Big Data e inteligência Artificial. Possui mais de 20 anos de trajetória nas áreas de Data Mining, Big Data, Inteligência Artificial e Analytics. Cientista de dados com carreira realizada na Universidade de São Paulo. Graduada e mestra em estatística aplicada pelo IME-USP e doutora pela FEA-USP. Com muita dedicação chegou ao cargo de professora e pesquisadora na FEA-USP, ganhou mais de 30 prêmios de excelência acadêmica pela FEA-USP e mais de 30 prêmios de excelência acadêmica como professora dos cursos de MBA da FIA. Orienta alunos de mestrado e de doutorado na FEA-USP. Membro do Conselho Curador da FIA, Coordenadora de Grupos de Pesquisa no CNPQ, Parecerista da FAPESP e Colunista de grandes Portais de Tecnologia.



[linkedin.com/in/alessandramontini/](https://www.linkedin.com/in/alessandramontini/)



Prof. Dr.  
**Adolpho Walter Canton**

Diretor do LABDATA-FIA. Consultor em Projetos de *Analytics*, *Big Data* e Inteligência Artificial. Professor FEA – USP. PhD em Estatística Aplicada pela *University of North Carolina at Chapel Hill*, Estados Unidos.



# CONTEÚDO PROGRAMÁTICO



ANÁLISE  
EXPLORATÓRIA

TÉCNICAS DE  
PROJEÇÃO

TÉCNICAS DE  
CLASSIFICAÇÃO

TÉCNICAS DE  
SEGMENTAÇÃO

TÉCNICAS DE  
ANALYTICS

LINGUAGEM



PYTHON



R

PROJETO



PROJETO ANALYTICS

# Conteúdo da Aula

- 1. Introdução
  - i. Componentes de uma Série Temporal
  - ii. Estacionariedade
  - iii. Metodologia de Box e Jenkins
- 2. Modelo Auto-regressivo: Ordens 1, 2, p e incompleto
  - i. Identificação
  - ii. Estimação
  - iii. Previsão
- 3. Exercícios para casa
  - CASE: *Call Center*
  - CASE: Retorno de Ações
  - Exercício de Fixação

# 1. Introdução



# Estrutura de dados de série histórica

## 1. INTRODUÇÃO | CARACTERÍSTICAS

9

Nesta aula trabalharemos com dados estruturados de forma longitudinal: séries de tempo univariadas. Diferente da estrutura de seção transversal (*cross sectional*) trabalhadas até o momento.

Data	Compra	Venda
01/04/2020	5,2399	5,2404
02/04/2020	5,2645	5,2651
03/04/2020	5,2991	5,2997
06/04/2020	5,2465	5,2471
07/04/2020	5,2211	5,2217
08/04/2020	5,2117	5,2123
09/04/2020	5,0773	5,0779
13/04/2020	5,1818	5,1824
14/04/2020	5,1852	5,1858
15/04/2020	5,2573	5,2579
16/04/2020	5,2371	5,2377
17/04/2020	5,2567	5,2573
20/04/2020	5,2831	5,2837
22/04/2020	5,3841	5,3847
23/04/2020	5,4461	5,4467
...	...	...



### Dados de séries históricas

São dados coletados ao longo de diversos períodos de tempo. Neste banco de dados, o valor do dólar foi analisado nos últimos 14 anos, na periodicidade diária.





# Objetivo

## 1. INTRODUÇÃO | SÉRIE TEMPORAL

12



As séries de tempo são analisadas com o objetivo de compreender o passado e projetar no futuro a mesma série de dados ao longo do tempo.

Uma característica importante das séries de tempo é que as observações vizinhas apresentam dependência entre si, e estamos interessados em modelar essa dependência.

Diferente dos modelos de regressão (dados com seção transversal) em que a ordem das observações apresentadas é irrelevante para análise de dados.




# Objetivo

## 1. INTRODUÇÃO | SÉRIE TEMPORAL

13

Na análise de série temporal observa-se a série em um período, obtém-se a equação de projeção e projeta-se os valores futuros com base no comportamento passado da série temporal.



<https://www.logianalytics.com/logi-news/logi-predict-product-update-key-enhancements/>



**Exemplo:** Prever a demanda de volumes financeiros sacados em caixas eletrônicos em todo o Brasil no próximo mês.

**Aplicação:** Bancos

**Importância para o negócio:** Planejar os volumes e periodicidade de abastecimento dos caixas eletrônicos, de forma a otimizar custos de transporte e satisfação de clientes.



Créditos: <https://pixabay.com/illustrations/atm-machine-using-screen-touch-3669795/>

# Aplicações de Análise de Séries Temporais em Indústrias Diversas

APLICAÇÕES | ANÁLISE DE SÉRIES TEMPORAIS

9

**Exemplo:** Prever a demanda de emplacamentos de carros novos da Fiat para os próximos 2 meses.

**Aplicação:** Indústria automobilística

**Importância para o negócio:** A partir da demanda prevista, ajustar os processos de produção e logística para atender a demanda potencial.



Créditos: <https://pixabay.com/photos/car-transparent-background-fiat-2170961/>

# Aplicações de Análise de Séries Temporais em Indústrias Diversas

APLICAÇÕES | ANÁLISE DE SÉRIES TEMPORAIS

10

**Exemplo:** Prever a demanda de desemprego no Brasil nos próximos 6 meses.

**Aplicação:** Governo

**Importância para o negócio:** A partir das perspectivas de desemprego, podem ser adotadas políticas públicas de geração de emprego, flexibilização de regras para trabalho informal, entre outras medidas.



Créditos: <https://pixabay.com/illustrations/atm-machine-using-screen-touch-3669795/>

**Exemplo:** Prever a demanda para os próximos 3 meses de um novo refrigerante que será lançado esse mês.

**Aplicação:** Indústria de bebidas

**Importância para o negócio:** Planejar aspectos de logística, distribuição e estratégia de vendas.



Créditos: <https://pixabay.com/illustrations/beverage-soft-drink-cans-1935287/>



# Aplicações de Análise de Séries Temporais em Indústrias Diversas

APLICAÇÕES | ANÁLISE DE SÉRIES TEMPORAIS

12

**Exemplo:** Prever a demanda de bilhetes aéreos vendidos para viagens ao exterior nos próximos 3 meses.

**Aplicação:** Empresas de Aviação

**Importância para o negócio:** Estabelecer preço, planejamento de rotas, disponibilidade de aeronaves.



Créditos: <https://pixabay.com/illustrations/future-vacations-plane-departure-1721268/>

# Aplicações de Análise de Séries Temporais em Indústrias Diversas

APLICAÇÕES | ANÁLISE DE SÉRIES TEMPORAIS

13

**Exemplo:** Prever o comportamento de um determinado papel na bolsa para os próximos 30 dias

**Aplicação:** Indústria financeira

**Importância para o negócio:** Tomar decisão de compra ou venda das ações do papel em questão.




Créditos: <https://pixabay.com/illustrations/success-curve-hand-finger-woman-1093891/>

**Exemplo:** Prever a demanda diária de energia para uma determinada região de distribuição na próxima semana, quinzena e mês.

**Aplicação:** Energia Elétrica

**Importância para o negócio:** Energia não se estoca. Se a demanda for mal projetada, ou tem perda por causa do excesso gerado ou, caso falte, a distribuidora tem que comprar energia no mercado livre de energia, cujo kWh é mais caro que o de geração própria.




Créditos: <https://pixabay.com/photos/power-lines-cables-tower-1868352/>

# Componentes de uma Série Temporal

1.i. COMPONENTES | SÉRIE TEMPORAL


15

Tendência



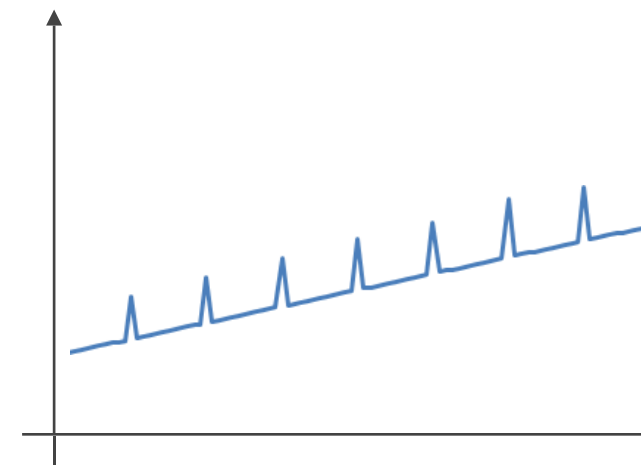
Esta série temporal apresenta **tendência**, pois os valores crescem ao longo do tempo.

Sazonalidade




Esta série apresenta sazonalidade, pois tem picos em determinados **períodos do ano**. Ex.: vendas no natal, dias das mães, etc.

Tendência e Sazonalidade



Esta série temporal apresenta **tendência e sazonalidade**, pois os valores crescem ao longo do tempo e apresentam picos em todo mês de dezembro, por exemplo.




# Séries Estacionárias

## 1.i. ESTACIONARIEDADE | SÉRIE TEMPORAL

18




Uma série temporal é estacionária quando oscila ao redor de uma **média constante**, refletindo um comportamento estável e aleatório ao longo do tempo.



A média da série é constante



### Exemplos de séries de tempo estacionárias:



Quando uma série é estacionária, a média e a variância são constantes, então elas dependem da distância dos passos (*lags* de defasagens) que as separam.









# Séries Não Estacionárias

## 1.i. ESTACIONARIEDADE | SÉRIE TEMPORAL

20

Uma série temporal não é estacionária quando:

- A média não é constante.
- A série apresenta tendência.



# Metodologia de Box e Jenkins

1.i. BOX E JENKIS | SÉRIETEMPORAL

21

Box e Jenkins (1976) propuseram uma metodologia para ajuste de **modelos de séries temporais estacionários** que é composta pelas seguintes etapas:

- i. Identificação
- ii. Estimação
- iii. Previsão



# Teste de Estacionariedade

1.i. BOX E JENKINS | SÉRIE TEMPORAL

22

Para o ajuste de uma série temporal por meio da metodologia de Box e Jenkins é necessário verificar se a série é estacionária, pois a metodologia de Box e Jenkins é aplicada quando a série é estacionária.


Apesar de ser possível visualizar graficamente a estacionariedade da série, pode-se utilizar o **teste de estacionariedade de Dickey-Fuller Aumentado** (Dickey & Fuller, 1979), com as seguintes hipóteses:

$H_0$ : a série não é estacionária

$H_1$ : a série é estacionária

**Regra de decisão:** Quando o nível descritivo é  $< 0,10$  rejeitamos  $H_0$ , ou seja, há evidência de que a série é estacionária.

Esta série temporal parece estacionária, pois oscila em torno de uma média constante.



# Modelos para Séries Estacionárias

1.i. BOX E JENKINS | SÉRIE TEMPORAL

23

A literatura de modelos de séries ao longo do tempo apresenta uma diversidade de famílias de modelos que podem ser utilizados para ajuste de séries estacionárias.

Na aula de hoje, será apresentado o **Modelo Auto-regressivo (AR)**, amplamente utilizado no mercado, em que a predição futura depende do comportamento passado da própria série, de um ou vários períodos históricos.



## 2. Modelo Auto-regressivo



# Modelo Auto-regressivo


## 2. MODELO AUTO-REGRESSIVO | SÉRIE TEMPORAL

25

Uma série temporal segue um processo auto-regressivo quando o valor da série no tempo  $t$  depende do que aconteceu em, por exemplo,  $t-1$ ,  $t-2$ ,  $t-3$ ,  $t-4$ , etc.

Em um modelo auto-regressivo, a previsão de valores futuros da série é realizada utilizando uma **combinação linear de valores do passado** da mesma série dedados.

O termo “auto-regressivo” indica a regressão da variável resposta contra ela mesma no passado.





# Exercício: AR(1)

## 2. MODELO AUTO-REGRESSIVO | SÉRIE TEMPORAL

26

Uma série temporal segue um processo auto-regressivo de ordem 1 ou AR(1) quando o valor da série no tempo  $t$  depende do valor da série em  $t-1$ .

$$Y_t = 24 + 0,823 * Y_{t-1}$$

$Y_t$ : valor previsto da série no instante  $t$

$Y_{t-1}$ : valor da série no instante  $t-1$



Seja  $Y$ , a variável quantidade de chamadas em uma central de atendimento de uma empresa de serviços que dá suporte para seus usuários, quando o serviço apresenta problemas de funcionamento. A variável  $Y$  é modelada na periodicidade diária.

**O gestor da área gostaria de saber qual será a quantidade de chamadas previstas para amanhã, dado que hoje o dia fechou com 321 chamadas.**



# Exercício: AR(2)

## 2. MODELO AUTO-REGRESSIVO | SÉRIE TEMPORAL

28

Uma série temporal segue um processo auto-regressivo de ordem 2 ou AR(2) quando o valor da série no tempo  $t$  depende do valor da série em  $t-1$  e  $t-2$ .

$$Y_t = 2,13 + 0,796 * Y_{t-1} + 0,235 * Y_{t-2}$$

$Y_t$  : valor previsto da série no instante  $t$

$Y_{t-1}$  : valor da série no instante  $t-1$

$Y_{t-2}$  : valor da série no instante  $t-2$



Seja  $Y_t$  a variável quantidade de vendas de um determinado item de um *e-commerce*. A variável  $Y_t$  é modelada na periodicidade mensal.

**O dono do *e-commerce* gostaria de saber qual será a projeção de vendas para o mês corrente, dado que no mês passado ele vendeu 456 itens e o mês retrasado 524.**



# Exercício: AR Incompleto - Ordens (2,5)

2. MODELO AUTO-REGRESSIVO | SÉRIE TEMPORAL

31

Uma série temporal segue um processo auto-regressivo de ordem incompleta, quando o valor da série no tempo  $t$  depende do valor da série em tempos passados específicos (não necessariamente com *lags* de defasagens consecutivas).

$$Y_t = 14,7 + 0,791 * Y_{t-2} + 0,125 * Y_{t-5}$$

$Y_t$  : valor previsto da série no instante  $t$

$Y_{t-2}$  : valor da série no instante  $t-2$

$Y_{t-5}$  : valor da série no instante  $t-5$



Seja  $Y$ , a variável quantidade de frutas que não foram vendidas (em um dia) de um grande Hortifruti. A variável  $Y$  é modelada na periodicidade diária.

**O gerente do Hortifruti, com o objetivo de evitar desperdício, gostaria de saber qual será a projeção de sobra de frutas hoje, tendo em mãos os dados da última semana:**

- **Ontem: 324**
- **Antes de ontem: 245**
- **t-3: 345**
- **t-4: 279**
- **t-5: 319**
- **t-6: 351**



# Metodologia de Box e Jenkins

## 2. MODELO AUTO-REGRESSIVO | SÉRIE TEMPORAL

32

Uma vez confirmado pelo teste de Dickey-Fuller Aumentado que a série é estacionária, pode-se utilizar a metodologia de Box e Jenkins, que consiste na realização das seguintes fases:

- i. Identificação
- ii. Estimação
- iii. Previsão



# 1. Fase de Identificação


2.i. IDENTIFICAÇÃO | METODOLOGIA DE BOX JENKINS

33


Para identificar se a série temporal segue um modelo Auto-regressivo, deve-se analisar as funções de autocorrelação (ACF – *autocorrelation function*) e autocorrelação parcial (PACF – *partial autocorrelation function*).

Esta é uma análise exploratória da série de dados para investigar as ordens a serem sugeridas para o modelo AR de maneira a se obter uma estrutura de modelo parcimoniosa.

Função Autocorrelação



Função de Autocorrelação Parcial



Para o modelo ser auto-regressivo, pela análise da ACF, várias autocorrelações devem apresentar valores diferentes de zero.

Note que a **ACF na lag zero será igual a um**, pois é a correlação da série no mesmo instante  $t$  contra ela mesma, ou seja, sem *lag* de defasagem.

Além disso, pela análise da PACF, as autocorrelações diferentes de ZERO dão um indicativo da ordem do AR que deve ser testada. No exemplo ao lado, AR(6).



# 2.1 Fase de Identificação

2.i. IDENTIFICAÇÃO | METODOLOGIA DE BOX EJENKINS

34

Para identificar se a série temporal segue um modelo Auto-regressivo deve-se analisar as funções de autocorrelação (ACF – *autocorrelation function*) e autocorrelação parcial (PACF – *partial autocorrelation function*).

O entendimento da autocorrelação e da autocorrelação parcial é:

## Autocorrelação

A autocorrelação mede a correlação linear entre as observações da série em diferentes períodos de tempos, ou seja, as correlações são calculadas nas *lags* defasadas em 1, 2, 3, 4, .... períodos de tempo. Denominamos essa defasagem como *lag 1*, *lag 2*, *lag 3*, *lag 4*, etc. Na *lag 0* a autocorrelação será sempre igual a 1.

## Autocorrelação Parcial

A função de autocorrelação parcial é útil para determinar a ordem de um processo AR. Por exemplo, um modelo será AR(1) se todas as autocorrelações parciais das ordens  $> 1$  forem iguais a zero. No geral, uma AR(k) terá sua autocorrelação parcial igual a zero depois da *lag k*.




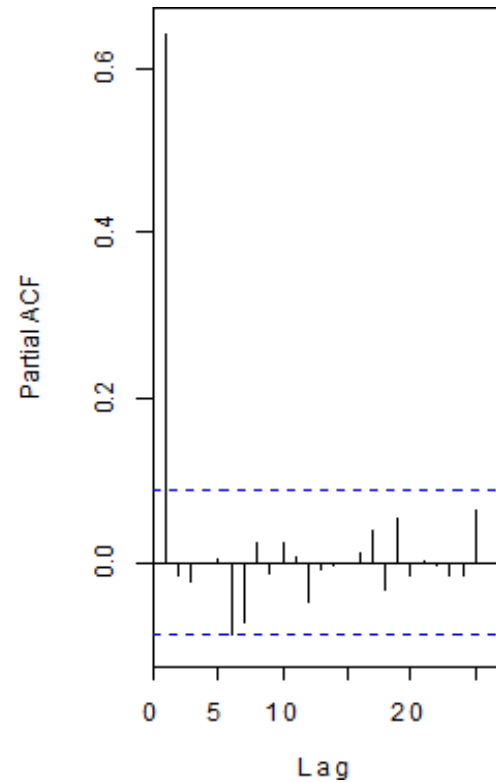





# Exercício: Identifique pelas ACF e ACFP se seriam modelos AR e qual sua ordem

2.i. IDENTIFICAÇÃO | METODOLOGIA DE BOX EJENKINS






35



# Exercício: Identifique pelas ACF e ACFP se seriam modelos AR e qual sua ordem

2.i. IDENTIFICAÇÃO | METODOLOGIA DE BOX EJENKINS

36



## 2.2 Fase de Estimação

2.ii. ESTIMAÇÃO | METODOLOGIA DE BOX EJENKINS

37

Uma vez identificada a ordem do modelo AR a ser testada, o próximo passo é estimar os parâmetros do modelo:

$$Y_t = \phi_0 + \phi_1 Y_{t-1} + \dots + \phi_p Y_{t-p}$$


$$\phi_0 = \text{intercepto}(1 - \phi_1 - \dots - \phi_p)$$

Teste de hipótese para cada um dos parâmetros  $i=0, 1, \dots, p$ :

$$H_0: \phi_i = 0$$

$$H_1: \phi_i \neq 0$$

Considerando 90 % de confiança da Distribuição Normal:



Quando o p-valor do teste estiver abaixo do nível descritivo adotado de 10% ou quando a estatística do teste estiver na região de rejeição, deve-se rejeitar  $H_0$ .





# Análise dos Resíduos: Funções de Autocorrelação e Autocorrelação Parcial

2.ii. ESTIMAÇÃO | METODOLOGIA DE BOX EJENKINS

38

Para avaliar o ajuste adequado do modelo, estudamos as funções de autocorrelação e autocorrelação parcial dos **resíduos**.

Nota: A autocorrelação de ordem 0 sempre é 1, pois é a correlação da série de resíduos contra ela mesma sem nenhuma *lag* de defasagem.



Há evidência de que todas as autocorrelações e todas as autocorrelações parciais são iguais a zero, pois estão dentro da linha pontilhada azul, portanto o modelo está adequado.



# Case *Call Center*: Realize as fase de identificação e estimação da série

2.ii. ESTIMAÇÃO | METODOLOGIA DE BOX EJENKINS

39

Com o objetivo de planejar a escala do time de *call center*, uma empresa de serviços gostaria de realizar a previsão da quantidade de recebimento de chamadas na próxima semana. A empresa possui o histórico da quantidade de chamadas recebidas (dias úteis) dos últimos 2 anos.



- (a) Faça a análise exploratória da série, e comente seu comportamento.
- (b) Construa o gráfico descritivo da série.
- (c) Teste se a série é estacionária.
- (d) Apresente graficamente a função de autocorrelação (ACF) e a função de autocorrelação parcial (PACF) e discuta sobre a ordem a ser testada no modelo AR.
- (e) Ajuste um modelo auto-regressivo AR e avalie a significância dos parâmetros.
- (f) Apresente graficamente a função de autocorrelação (ACF) e a função de autocorrelação parcial (PACF) dos resíduos do modelo e discuta se a ordem do AR adotada está adequada.
- (g) Uma vez o modelo bem ajustado, apresente a equação do modelo.
- (h) Faça a previsão para a próxima semana (dias úteis) e comente os resultados.

Vamos fazer  
juntos?

R Studio®




# Case Call Center: Análise Exploratória



2.ii. ESTIMAÇÃO | METODOLOGIA DE BOX EJENKINS

40

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
249.0	711.0	884.0	877.5	1036.5	1591.0



Augmented Dickey-Fuller Testdata:  
p-value = 0.01  
alternative hypothesis: stationary



# Case Call Center: Ajuste do modelo no R


2.ii. ESTIMAÇÃO | METODOLOGIA DE BOX EJENKINS

41


	Estimate	Std. Error	z value	Pr(> z )
Ar1	0.381796	0.046054	8.2902	< 2e-16 ***
Ar2	-0.103981	0.046044	-2.2583	0.02393 *
Intercept	877.396897	14.282585	61.4312	< 2e-16 ***

--- Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Series residuals(modelo)



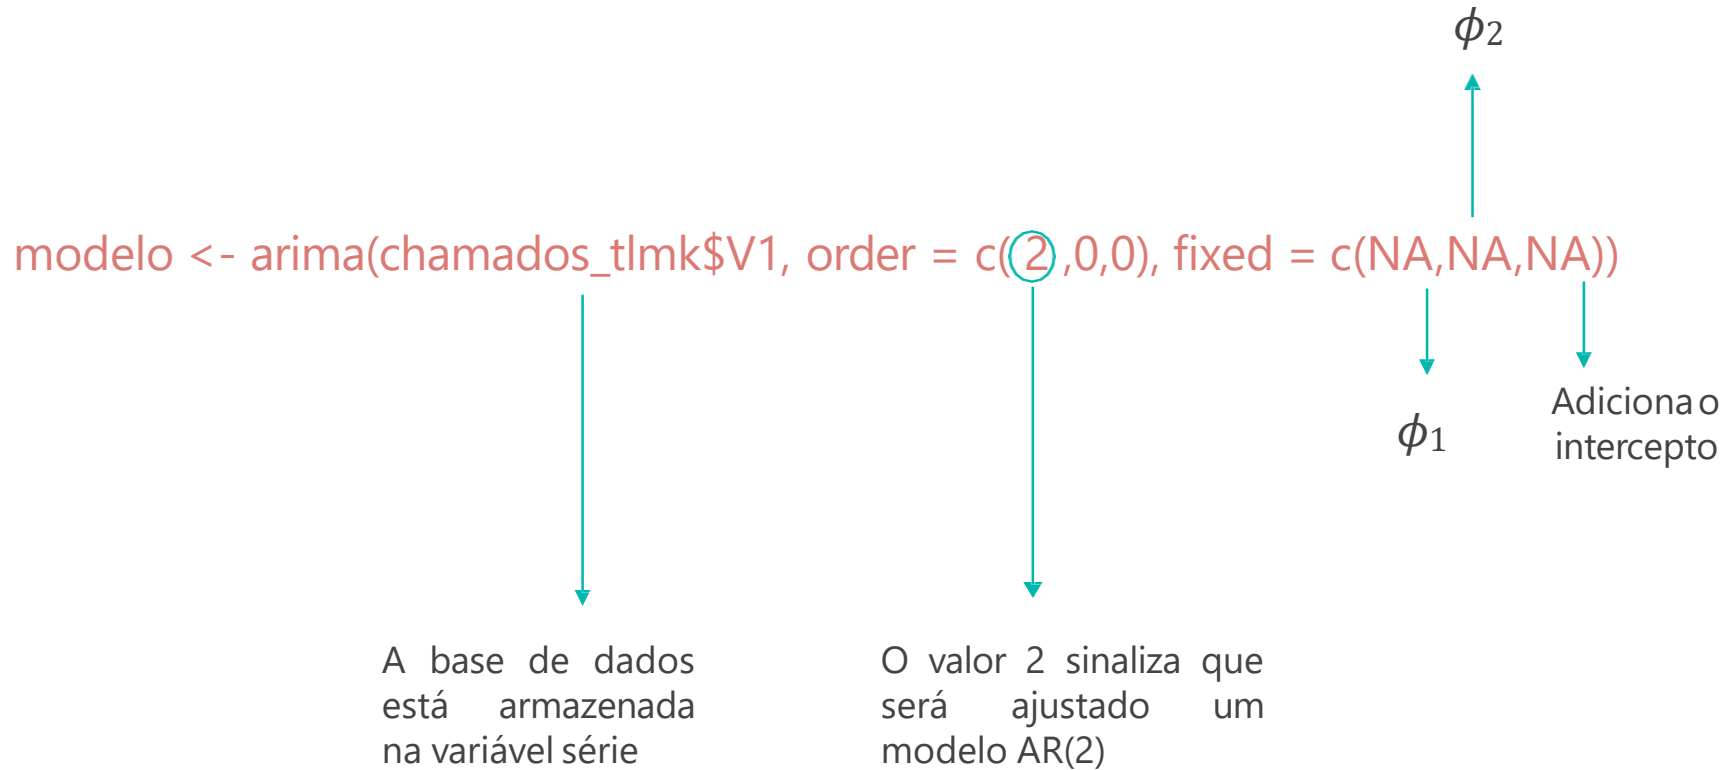
Series residuals(modelo)



# Case Call Center: Ajuste do modelo no R

2.ii. ESTIMAÇÃO | METODOLOGIA DE BOX EJENKINS

42





## 2.3 Fase de Previsão

2.iii. PREVISÃO | METODOLOGIA DE BOX EJENKINS

43

Uma vez o modelo bem ajustado, pode-se obter por meio da equação do modelo a previsão N passos para frente.

$$Y_t = \phi_0 + \phi_1 Y_{t-1} + \dots + \phi_p Y_{t-p}$$

$$\phi_0 = \text{intercepto}(1 - \phi_1 - \dots - \phi_p)$$

### Projeção N passos para frente:

Com base na equação do modelo, utilizando os dados das *lags* passadas é possível prever passos para frente, ou seja, fazer projeção para o futuro de dados ainda não conhecidos.




# Case *Call Center*: Realize as fase de identificação e estimação da série

2.iii. PREVISÃO | METODOLOGIA DE BOX EJENKINS

44

Com o objetivo de planejar a escala do time de *call center*, uma empresa de serviços gostaria de realizar a previsão da quantidade de recebimento de chamadas na próxima semana. A empresa possui o histórico da quantidade de chamadas recebidas (dias úteis) dos últimos 2 anos.



- (a) Faça a análise exploratória da série, e comente seu comportamento.
- (b) Construa o gráfico descritivo da série.
- (c) Teste se a série é estacionária.
- (d) Apresente graficamente a função de autocorrelação (ACF) e a função de autocorrelação parcial (PACF) e discuta sobre a ordem a ser testada no modelo AR.
- (e) Ajuste um modelo auto-regressivo AR e avalie a significância dos parâmetros.
- (f) Apresente graficamente a função de autocorrelação (ACF) e a função de autocorrelação parcial (PACF) dos resíduos do modelo e discuta se a ordem do AR adotada está adequada.
- (g) Uma vez o modelo bem ajustado, apresente a equação do modelo.
- (h) Faça a previsão para a próxima semana (dias úteis) e comente os resultados.



# Case Call Center: Ajuste do modelo no R

2.iii. PREVISÃO | METODOLOGIA DE BOX JENKINS

45

Uma vez o modelo bem ajustado, pode-se obter por meio da equação do modelo a previsão 5 passos para frente.

$$Y_t = \phi_0 + \phi_1 Y_{t-1} + \dots + \phi_p Y_{t-p}$$

$$\phi_0 = \text{intercepto}(1 - \phi_1 - \dots - \phi_p)$$

Equação do modelo AR(2):

$$Y_{tT} = 633,64 + 0,3818 * Y_{t-1} - 0,1040 * Y_{t-2}$$

$$Y_{467} = 633,64 + 0,3818 * 627 - 0,1040 * 711 = 799,1$$


$$Y_{468} = 633,64 + 0,3818 * 799,1 - 0,1040 * 627 = 873,6$$

.....


↑ Valor obtido na predição  
do passo anterior

**Projeção 5 passos para frente:**

	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
467	799.0986	513.5981	1084.599	362.4632	1235.734
468	873.5395	567.9382	1179.141	406.1626	1340.916
469	884.0657	578.2316	1189.900	416.3328	1351.799
470	880.3441	574.4349	1186.253	412.4963	1348.192
471	877.8287	571.8955	1183.762	409.9443	1345.713



657  
902  
1256  
1049  
897  
722  
972  
869  
720  
699  
734  
899  
734  
1076  
753  
638  
445  
1118  
1039  
995  
711  
627



# Aplicação: Séries Temporais Financeiras

## 2. MODELO AUTO-REGRESSIVO | RETORNO

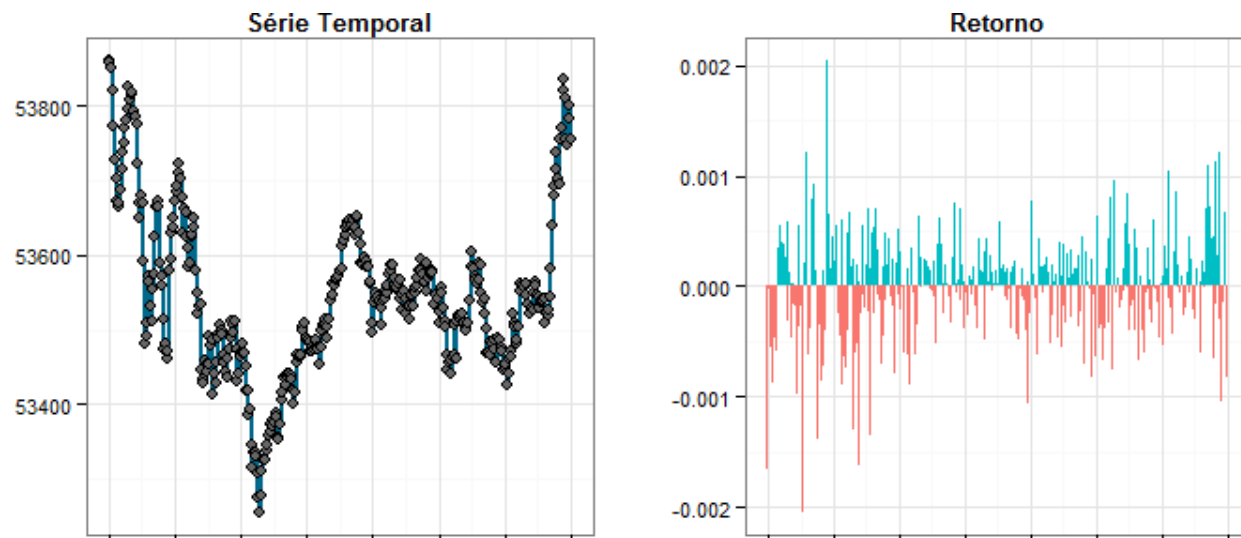
46

Um dos objetivos no mercado financeiro é avaliação do risco do preço dos ativos (Morettin, 2008).

O risco é frequentemente medido em termos das **variações de preços dos ativos**, denominado **Retorno**. Seja  $P_t$  o preço de um ativo no tempo  $t$ , a taxa de retorno  $R_t$  é definida por:

$$R = \frac{P_t - P_{t-1}}{P_{t-1}}$$

**Exemplo:** Ações da Petrobrás medidas a cada minuto, com um total de 401 observações:



No mercado, é comum trabalhar com os retornos ao invés do preço dos ativos, que além de serem livres de escala, possuem propriedades interessantes como **obtenção da estacionariedade**, possibilitando, por exemplo, o uso de modelos AR.

<http://www.portaaction.com.br/series-temporais/51-retornos>



# Case Retorno Ações

2. MODELO AUTO-REGRESSIVO | METODOLOGIA DE BOX E JENKINS

47

Um investidor deseja saber se aconselhável investir em um determinado tipo de ação na próxima semana. Ele tem disponível os dados históricos dos últimos 2 anos. Realize uma análise desta série de retornos e avalie a possibilidade do ajuste de um modelo AR. Identifique sua ordem e realize a previsão para a próxima semana.



- (a) Faça a análise exploratória da série, e comente os números na visão de negócios.
- (b) Construa o gráfico descritivo da série e comente seu comportamento.
- (c) Teste se a série é estacionária. Comente sobre a regra de decisão.
- (d) Apresente graficamente a função de autocorrelação (ACF) e a função de autocorrelação parcial (PACF) e discuta sobre a ordem a ser testada no modelo AR.
- (e) Ajuste um modelo auto-regressivo AR e avalie a significância dos parâmetros.
- (f) Apresente graficamente a função de autocorrelação (ACF) e a função de autocorrelação parcial (PACF) dos resíduos do modelo e discuta se a ordem do AR adotada está adequada.
- (g) Uma vez o modelo bem ajustado, apresente a equação do modelo.
- (h) Após a próxima semana ter passado, os dados observados foram os seguintes: 0.103906254, 0.188157433, -0.080349801, 0.11583838, 0.121133841. Compare sua predição com os resultados observados. Discuta se o modelo foi bem ajustado.



# Modelo AR Incompleto: Ajuste no R

2.ii. ESTIMAÇÃO | METODOLOGIA DE BOX EJENKINS

48

```
modelo <- arima(retorno$V1, order = c(5,0,0), fixed = c(NA,NA,NA,0,NA,0))
```

A base de dados  
está armazenada na  
variável série

O valor 5 sinaliza  
que será ajustado  
um modelo AR(5)

$\phi_1$

$\phi_2$

$\phi_3$

retira o  
intercepto

$\phi_4$

retira a  
ordem 4

$\phi_5$



## 3. Exercícios



Com o objetivo de planejar a escala do time de *call center*, uma empresa de serviços gostaria de realizar a previsão da quantidade de recebimento de chamadas na próxima semana. A empresa possui o histórico da quantidade de chamadas recebidas (dias úteis) dos últimos 2 anos.



**Os outputs em R já foram gerados durante a aula. Escreva a interpretação dos resultados dos itens (a)-(h) e responda a pergunta de negócios em (i).**

- (a) Faça a análise exploratória da série, e comente os números na visão de negócios.
- (b) Construa o gráfico descritivo da série e comente seu comportamento.
- (c) Teste se a série é estacionária. Comente sobre a regra de decisão.
- (d) Apresente graficamente a função de autocorrelação (ACF) e a função de autocorrelação parcial (PACF) e discuta sobre a ordem a ser testada no modelo AR.
- (e) Ajuste um modelo auto-regressivo AR e avalie a significância dos parâmetros.
- (f) Apresente graficamente a função de autocorrelação (ACF) e a função de autocorrelação parcial (PACF) dos resíduos do modelo e discuta se a ordem do AR adotada está adequada.
- (g) Uma vez o modelo bem ajustado, apresente a equação do modelo.
- (h) Faça a previsão para a próxima semana (dias úteis) e comente os resultados da estimativa pontual.
- (i) Discuta na visão de negócios se você recomendaria fazer a previsão para a próxima semana ou se o ideal seria fornecer a previsão em um período diferente (maior ou menor do que 5 dias).**





Um investidor deseja saber se aconselhável investir em um determinado tipo de ação na próxima semana. Ele tem disponível os dados históricos dos últimos 2 anos. Realize uma análise desta série de retornos e avalie a possibilidade do ajuste de um modelo AR. Identifique sua ordem e realize a previsão para a próxima semana.



**Os outputs em R já foram gerados durante a aula. Escreva a interpretação dos resultados dos itens (a)-(h) e responda a pergunta de negócios em (i).**

- (a) Faça a análise exploratória da série, e comente os números na visão de negócios.
- (b) Construa o gráfico descritivo da série e comente seu comportamento.
- (c) Teste se a série é estacionária. Comente sobre a regra de decisão.
- (d) Apresente graficamente a função de autocorrelação (ACF) e a função de autocorrelação parcial (PACF) e discuta sobre a ordem a ser testada no modelo AR.
- (e) Ajuste um modelo auto-regressivo AR e avalie a significância dos parâmetros.
- (f) Apresente graficamente a função de autocorrelação (ACF) e a função de autocorrelação parcial (PACF) dos resíduos do modelo e discuta se a ordem do AR adotada está adequada.
- (g) Uma vez o modelo bem ajustado, apresente a equação do modelo.
- (h) Após a próxima semana ter passado, os dados observados foram os seguintes: 0.103906254, 0.188157433, -0.080349801, 0.11583838, 0.121133841. Compare sua previsão com os resultados observados. Discuta se o modelo foi bem ajustado.
- (i) Discuta na visão de negócios se você recomendaria para um investidor realizar o investimento no ativo em questão.**



- Box, G. E. P. & Jenkins, G. M. (1976). *Time series analysis: Forecasting and control*. San Francisco: Holden-Day.
- Dickey, D. & Fuller, W. A. (1979). *Distribution of the estimates for autoregressive time series with a unit root*. Journal of the American Statistical Association, 74(2), 427-431.
- Morettin, P. A. & Toloi, C. M. de C. (2004). *Análise de séries temporais*. São Paulo: Edgard Blücher.
- Morettin, P. A. (2008). *Econometria financeira: um curso em séries temporais financeiras*. São Paulo: Edgard Blücher.

