

Analytics e Inteligência Artificial

Tema da aula
Séries Temporais



BUSINESS SCHOOL

Graduação, pós-graduação,
MBA, Pós- MBA, Mestrado
Profissional, Curso In
Company e EAD



CONSULTING

Consultoria personalizada
que oferece soluções
baseada em seu problema
de negócio



RESEARCH

Atualização dos
conhecimentos e do material
didático oferecidos nas
atividades de ensino



Líder em Educação Executiva, referência de ensino nos cursos de graduação, pós-graduação e MBA, tendo excelência nos programas de educação. Uma das principais **escolas de negócio do mundo**, possuindo convênios internacionais com Universidades nos EUA, Europa e Ásia. +8.000 **projetos de consultorias** em organizações públicas e privadas.



Único curso de
graduação em
administração a
receber as
notas máximas



A primeira escola
brasileira a ser
finalista da maior
competição de MBA
do mundo



Única *Business
School*
brasileira a
figurar no
ranking LATAM



Signatária do
Pacto Global
da ONU



Membro
fundador da
ANAMBA -
Associação
Nacional MBAs



Credenciada
pela AMBA -
Association of
MBAs



Credenciada ao
Executive MBA
Council



Filiada a AACSB
- Association to
Advance
Collegiate
Schools of
Business



Filiada a EFMD
- European
Foundation for
Management
Development



Referência em
cursos de MBA
nas principais
mídias de
circulação

O **Laboratório de Análise de Dados** – LABDATA é um Centro de Excelência que atua nas áreas de ensino, pesquisa e consultoria em análise de informação utilizando técnicas de **Big Data, Analytics** e **Inteligência Artificial**.



Profª Drª Alessandra Montini

O LABDATA é um dos pioneiros no lançamento dos cursos de *Big Data* e *Analytics* no Brasil

Os diretores foram professores de grandes especialistas do mercado

+10 anos de atuação

+1000 alunos formados

Docentes

- Sólida formação acadêmica: doutores e mestres em sua maioria
- Larga experiência de mercado na resolução de *cases*
- Participação em Congressos Nacionais e Internacionais
- Professor assistente que acompanha o aluno durante todo o curso

Estrutura

- 100% das aulas realizadas em laboratórios
- Computadores para uso individual durante as aulas
- 5 laboratórios de alta qualidade (investimento +R\$2MM)
- 2 Unidades próximas a estação de metrô (com estacionamento)



Profª Dra.
Alessandra Montini

Diretora do LABDATA-FIA, apaixonada por dados e pela arte de lecionar. Têm muito orgulho de ter criado na FIA cinco laboratórios para as aulas de Big Data e inteligência Artificial. Possui mais de 20 anos de trajetória nas áreas de Data Mining, Big Data, Inteligência Artificial e Analytics. Cientista de dados com carreira realizada na Universidade de São Paulo. Graduada e mestra em estatística aplicada pelo IME-USP e doutora pela FEA-USP. Com muita dedicação chegou ao cargo de professora e pesquisadora na FEA-USP, ganhou mais de 30 prêmios de excelência acadêmica pela FEA-USP e mais de 30 prêmios de excelência acadêmica como professora dos cursos de MBA da FIA. Orienta alunos de mestrado e de doutorado na FEA-USP. Membro do Conselho Curador da FIA, Coordenadora de Grupos de Pesquisa no CNPQ, Parecerista da FAPESP e Colunista de grandes Portais de Tecnologia.



[linkedin.com/in/alessandramontini/](https://www.linkedin.com/in/alessandramontini/)



Prof. Dr.
Adolpho Walter Canton

Diretor do LABDATA-FIA. Consultor em Projetos de *Analytics*, *Big Data* e Inteligência Artificial. Professor FEA – USP. PhD em Estatística Aplicada pela *University of North Carolina at Chapel Hill*, Estados Unidos.

CONTEÚDO PROGRAMÁTICO



ANÁLISE
EXPLORATÓRIA

TÉCNICAS DE
PROJEÇÃO

TÉCNICAS DE
CLASSIFICAÇÃO

TÉCNICAS DE
SEGMENTAÇÃO

TÉCNICAS DE
ANALYTICS

LINGUAGEM



PYTHON



PROJETO



PROJETO ANALYTICS


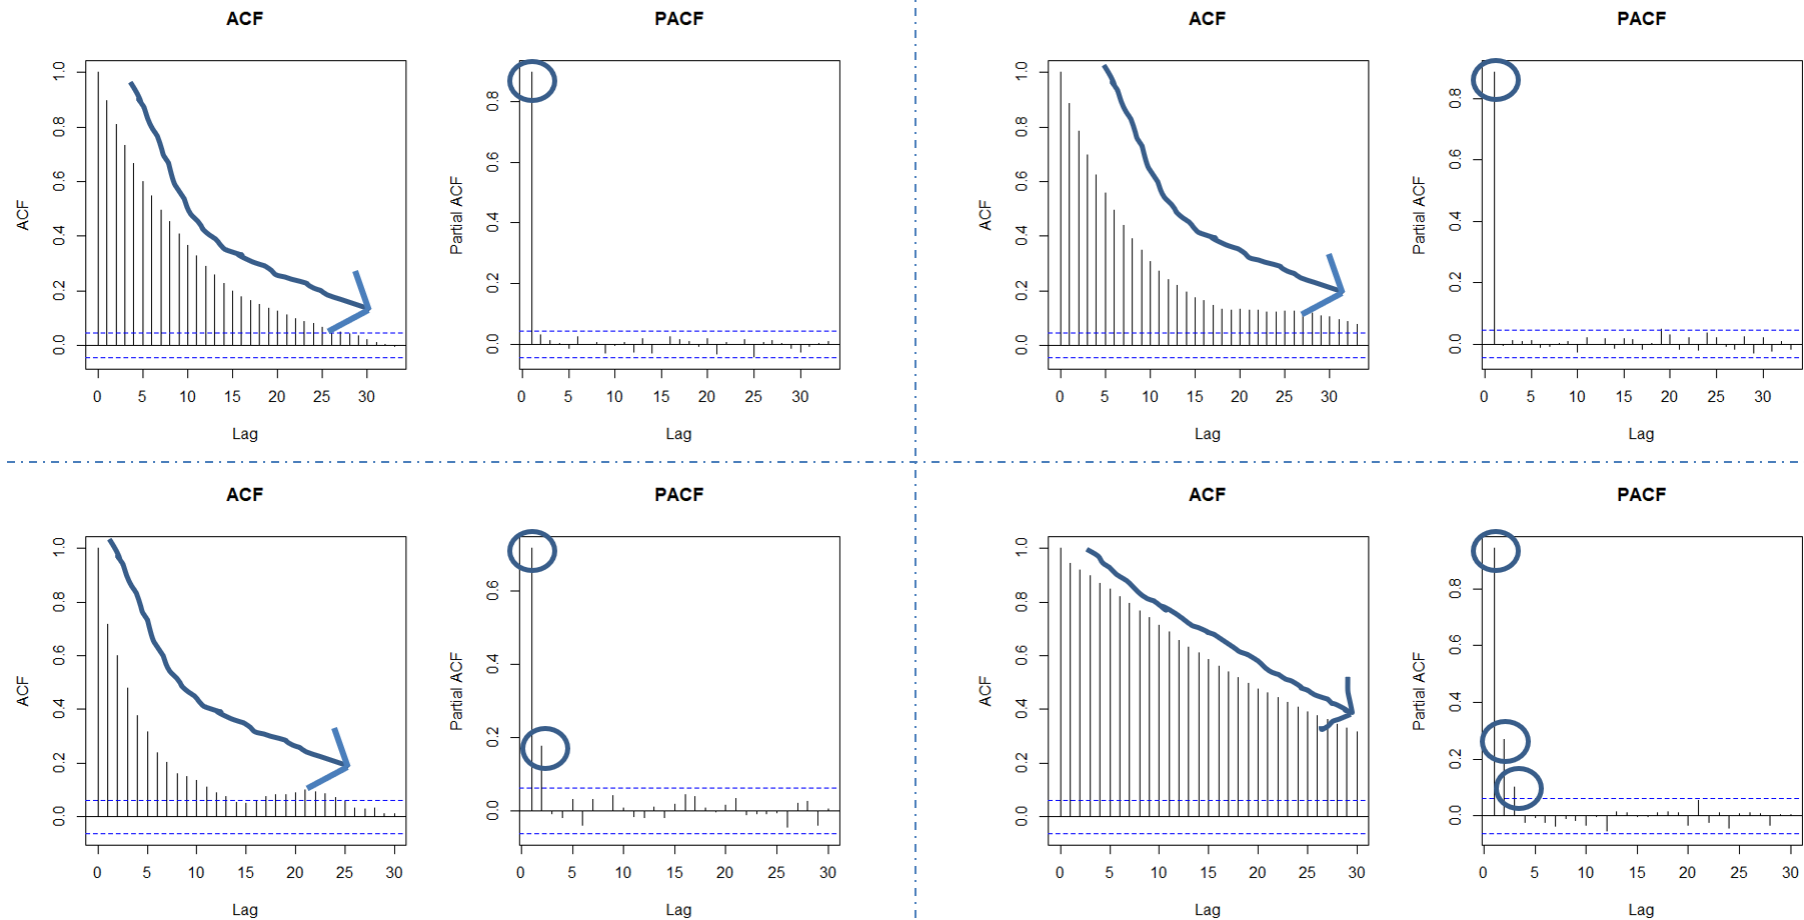
Conteúdo da Aula

- 1. Introdução
- 2. Modelo Médias-móveis: Ordens 1, 2, q
 - i. Identificação
 - ii. Estimação
- 3. Exercícios para Fixação

1. Introdução




Vimos algo em comum em todas as séries até agora: existem várias autocorrelações diferentes de zero.



Em alguns casos, não existem várias autocorrelações diferentes de zero.

Nesses casos, não é possível ajustar um modelo autorregressivo(AR).



2. Modelo de Médias Móveis



Modelo Médias Móveis

2. MODELO MÉDIAS MOVEIS | SÉRIE TEMPORAL

25

Uma série temporal segue um processo de médias móveis quando o valor da série no tempo t depende somente dos valores dos erros do modelo em $t-1$, $t-2$, $t-3$, etc.

Erro é o valor observado da série temporal menos o valor ajustado pelo modelo.

Quando uma empresa projeta uma venda em 10 milhões de reais e a venda real é de 8 milhões de reais, o erro do modelo é de -2 milhões de reais.



Exemplo: MA(1)

2. MODELO MÉDIAS MÓVEIS | SÉRIE TEMPORAL

26


Uma série temporal segue um processo de médias móveis de ordem 1 ou MA(1) quando o valor da série no tempo t depende somente dos valores dos erros no modelo em $t-1$.

$$Y_t = 500 + 0,12 * \varepsilon_{t-1}$$

Y_t : valor previsto da série no instante t

ε_{t-1} : valor do erro do modelo no instante $t-1$

Seja Y , a variável vendas mensais de uma empresa de Cosméticos, o gestor da área gostaria de saber qual será a venda de março sabendo que o erro do modelo em fevereiro foi de 50 unidades.



Exemplo: MA(1)

2. MODELO MÉDIAS MÓVEIS | SÉRIETEMPORAL

26

Uma série temporal segue um processo de médias móveis de ordem 1 ou MA(1) quando o valor da série no tempo t depende somente dos valores dos erros no modelo em $t-1$.

$$Y_t = 500 + 0,12 * \varepsilon_{t-1}$$

Y_t : valor previsto da série no instante t

ε_{t-1} : valor do erro do modelo no instante $t-1$

Seja Y , a variável vendas mensais de uma empresa de Cosméticos, o gestor da área gostaria de saber qual será a venda de março sabendo que o erro do modelo em fevereiro foi de 50 unidades.

$$Y_t = 500 + 0,12 * \varepsilon_{t-1}$$

$$Y_t = 500 + 0,12 * 50$$

$$Y_t = 506$$



Exercício: MA(1)

2. MODELO MÉDIAS MÓVEIS | SÉRIE TEMPORAL

26

Uma série temporal segue um processo de médias móveis de ordem 1 ou MA(1) quando o valor da série no tempo t depende somente dos valores dos erros no modelo em $t-1$.

$$Y_t = 600 + 0,45 * \varepsilon_{t-1}$$

Y_t : valor previsto da série no instante t

ε_{t-1} : valor do erro do modelo no instante $t-1$



Seja Y , a variável vendas mensais de uma empresa de esportes, a diretora da área gostaria de saber qual será a venda de outubro sabendo que o erro do modelo em setembro foi de 30 unidades.



Exemplo: MA(2)

2. MODELO MÉDIAS MÓVEIS | SÉRIE TEMPORAL

26

Uma série temporal segue um processo de médias móveis de ordem 2 ou MA(2) quando o valor da série no tempo t depende somente dos valores dos erros no modelo em $t-1$ e $t-2$.

$$Y_t = 300 + 0,12 * \varepsilon_{t-1} + 0,08 * \varepsilon_{t-2}$$

Y_t : valor previsto da série no instante t

ε_{t-1} : valor do erro do modelo no instante $t-1$

ε_{t-2} : valor do erro do modelo no instante $t-2$

Seja Y , a variável vendas mensais de uma empresa de eletrodomésticos, o coordenador da área gostaria de saber qual será a venda de julho sabendo que o erro do modelo em junho foi de 50 unidades e o erro em maio foi de 30 unidades.



Exemplo: MA(2)

2. MODELO MÉDIAS MÓVEIS | SÉRIE TEMPORAL

26

Uma série temporal segue um processo de médias móveis de ordem 2 ou MA(2) quando o valor da série no tempo t depende somente dos valores dos erros no modelo em $t-1$ e $t-2$.

$$Y_t = 300 + 0,12 * \varepsilon_{t-1} + 0,08 * \varepsilon_{t-2}$$

Y_t : valor previsto da série no instante t

ε_{t-1} : valor do erro do modelo no instante $t-1$

ε_{t-2} : valor do erro do modelo no instante $t-2$

Seja Y , a variável vendas mensais de uma empresa de eletrodomésticos, o coordenador da área gostaria de saber qual será a venda de julho sabendo que o erro do modelo em junho foi de 50 unidades e o erro em maio foi de 30 unidades.

$$Y_t = 300 + 0,12 * \varepsilon_{t-1} + 0,08 * \varepsilon_{t-2}$$

$$Y_t = 300 + 0,12 * 50 + 0,08 * 30$$

$$Y_t = 308$$



Exercício: MA(2)

2. MODELO MÉDIAS MÓVEIS | SÉRIE TEMPORAL

26

Uma série temporal segue um processo de médias móveis de ordem 2 ou MA(2) quando o valor da série no tempo t depende somente dos valores dos erros no modelo em $t-1$ e $t-2$.

$$Y_t = 100 + 0,22 * \varepsilon_{t-1} + 0,15 * \varepsilon_{t-2}$$

Y_t : valor previsto da série no instante t

ε_{t-1} : valor do erro do modelo no instante $t-1$

ε_{t-2} : valor do erro do modelo no instante $t-2$

Seja Y , a variável número de festas mensais de um buffet, a coordenadora da área gostaria de saber qual será a venda de julho sabendo que o erro do modelo em junho foi de 10 unidades e o erro em maio foi de 18 unidades.



Exercício: MA(2)

2. MODELO MÉDIAS MÓVEIS | SÉRIE TEMPORAL

26

Uma série temporal segue um processo de médias móveis de ordem 2 ou MA(2) quando o valor da série no tempo t depende somente dos valores dos erros no modelo em $t-1$ e $t-2$.

$$Y_t = 100 + 0,22 * \varepsilon_{t-1} + 0,15 * \varepsilon_{t-2}$$

Y_t : valor previsto da série no instante t

ε_{t-1} : valor do erro do modelo no instante $t-1$

ε_{t-2} : valor do erro do modelo no instante $t-2$

Seja Y , a variável número de festas mensais de um buffet, a coordenadora da área gostaria de saber qual será a venda de julho sabendo que o erro do modelo em junho foi de 10 unidades e o erro em maio foi de 18 unidades.

$$Y_t = 100 + 0,22 * \varepsilon_{t-1} + 0,15 * \varepsilon_{t-2}$$

$$Y_t = 100 + 0,22 * 10 + 0,15 * 18$$

$$Y_t = 105$$




Séries Estacionárias

2.1 MODELO MÉDIAS MÓVEIS | SÉRIE TEMPORAL

18

Uma série temporal é estacionária quando oscila ao redor de uma **média constante**, refletindo um comportamento estável e aleatório ao longo do tempo.



A média da série é constante



Teste de Estacionariedade

2.1. BOX E JENKINS | SÉRIE TEMPORAL

22

Para o ajuste de uma série temporal por meio da metodologia de Box e Jenkins é necessário verificar se a série é estacionária, pois a metodologia de Box e Jenkins é aplicada quando a série é estacionária.


Apesar de ser possível visualizar graficamente a estacionariedade da série, pode-se utilizar o **teste de estacionariedade de Dickey-Fuller Aumentado** (Dickey & Fuller, 1979), com as seguintes hipóteses:

H_0 : a série não é estacionária

H_1 : a série é estacionária

Regra de decisão: Quando o nível descritivo é $< 0,10$ rejeitamos H_0 , ou seja, há evidência de que a série é estacionária.

Esta série temporal parece estacionária, pois oscila em torno de uma média constante.



Metodologia de Box e Jenkins

2.1 MODELO AUTO-REGRESSIVO | SÉRIE TEMPORAL

Uma vez confirmado pelo teste de Dickey-Fuller Aumentado que a série é estacionária, pode-se utilizar a metodologia de Box e Jenkins, que consiste na realização das seguintes fases:

- i. Identificação
- ii. Estimação
- iii. Previsão



1. Fase de Identificação


2.i. IDENTIFICAÇÃO | METODOLOGIA DE BOX JENKINS

33


Para identificar se a série temporal segue um modelo de Médias Móveis, deve-se analisar as funções de autocorrelação (ACF – *autocorrelation function*) e autocorrelação parcial (PACF – *partial autocorrelation function*).

Esta é uma análise exploratória da série de dados para investigar as ordens a serem sugeridas para o modelo MA de maneira a se obter uma estrutura de modelo parcimoniosa.

Função Autocorrelação



Função de Autocorrelação Parcial



Para o modelo ser Médias Móveis, pela análise da PACF, várias autocorrelações parciais devem apresentar valores diferentes de zero.

Note que a **ACF na lag zero será igual a um**, pois é a correlação da série no mesmo instante t contra ela mesma, ou seja, sem *lag* de defasagem.

Além disso, pela análise da ACF, devemos ter algumas autocorrelações diferentes de zero. Como apenas a autocorrelação de ordem 1 é diferente de zero, deve-se ajustar um modelo de médias móveis de ordem 1, MA(1).



1. Fase de Identificação

2.i. IDENTIFICAÇÃO | METODOLOGIA DE BOX EJENKINS

33






Gráfico	AR	MA
ACF	Várias autocorrelações diferentes de 0	Ordem q
PACF	Ordem p	Várias autocorrelações diferentes de 0



Exercício: Identifique pelas ACF e ACFP se seriam modelos MA e qual sua ordem

2.i. IDENTIFICAÇÃO | METODOLOGIA DE BOX EJENKINS

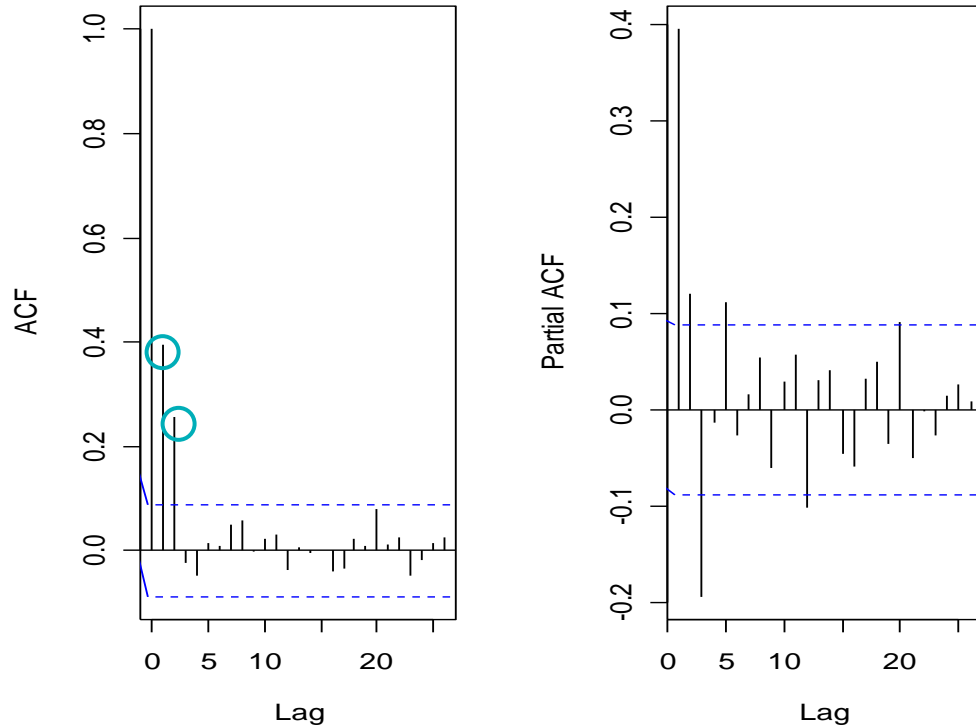
36




Exercício: Identifique pelas ACF e ACFP se seriam modelos MA e qual sua ordem

2.i. IDENTIFICAÇÃO | METODOLOGIA DE BOX EJENKINS


36



Há evidências de que a série temporal segue um modelo MA(2), pois existem várias autocorrelações parciais diferentes de zero e apenas as autocorrelações 1 e 2 são diferentes de zero.



Há evidências de que a série temporal segue um modelo MA(3), pois existem várias autocorrelações parciais diferentes de zero e apenas as autocorrelações 1, 2 e 3 são diferentes de zero.



2.2 Fase de Estimação

2.ii. ESTIMAÇÃO | METODOLOGIA DE BOX EJENKINS

37

Uma vez identificada a ordem do modelo MA a ser testada, o próximo passo é estimar os parâmetros do modelo:


$$Y_t = \theta_0 + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q}$$

Teste de hipótese para cada um dos parâmetros $i=0, 1, \dots, q$

$$H_0: \theta_i = 0$$

$$H_1: \theta_i \neq 0$$

Considerando 90 % de confiança da Distribuição Normal:



Quando o p-valor do teste estiver abaixo do nível descritivo adotado de 10% ou quando a estatística do teste estiver na região de rejeição, deve-se rejeitar H_0 .



Case Serie 14: Realize as fase de identificação e estimação da série

2.ii. ESTIMAÇÃO | METODOLOGIA DE BOX EJENKINS

39

Ao observar a queda no número de vendas de um produto, um gestor gostaria de saber qual será a venda estimada para o próximo mês, uma vez que, ele gostaria de saber se o número de itens no estoque será suficiente para atender a demanda ou se vale a pena fazer um novo pedido.



- (a) Faça a análise exploratória da série, e comente seu comportamento.
- (b) Construa o gráfico descritivo da série.
- (c) Teste se a série é estacionária.
- (d) Apresente graficamente a função de autocorrelação (ACF) e a função de autocorrelação parcial (PACF) e discuta sobre a ordem a ser testada no modelo MA.
- (e) Ajuste um modelo Médias Móveis MA e avalie a significância dos parâmetros.
- (f) Apresente graficamente a função de autocorrelação (ACF) e a função de autocorrelação parcial (PACF) dos resíduos do modelo e discuta se a ordem do AR adotada está adequada.
- (g) Escreva a equação do modelo

Vamos fazer
juntos?

 **Studio**




Case Serie 14 : Análise Exploratória



2.ii. ESTIMAÇÃO | METODOLOGIA DE BOX EJENKINS

40

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
-4.034	-0.736	-0.034	-0.020	0.689	3.457



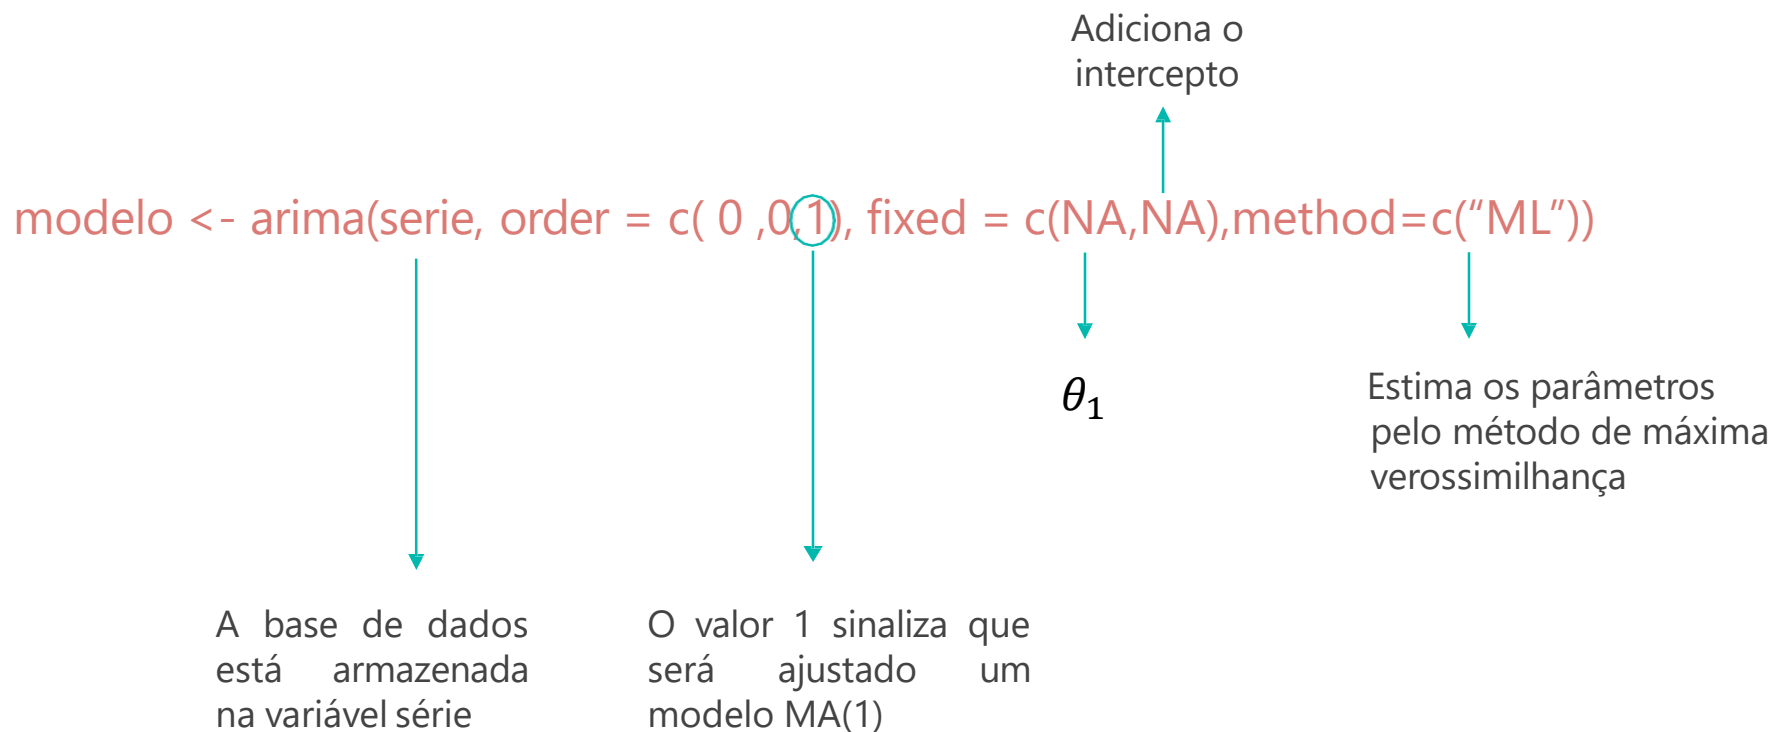
Augmented Dickey-Fuller Testdata:
p-value = 0.01
alternative hypothesis: stationary



Case Serie 14 : Ajuste do modelo no R

2.ii. ESTIMAÇÃO | METODOLOGIA DE BOX EJENKINS

42



Case Serie 14 : Ajuste do modelo no R

2.ii. ESTIMAÇÃO | METODOLOGIA DE BOX EJENKINS

41

z test of coefficients:

```
      Estimate Std. Error z value      Pr(>|z|)
ma1      0.408268   0.020300  20.112 <0.0000000000000002 ***
intercept -0.020364   0.031332  -0.650      0.5157
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```


Como o **p-valor associado ao intercepto é maior que 0,10***, há evidência que é igual a 0 e deve ser retirado do modelo.



Case Serie 14 : Ajuste do modelo no R

2.ii. ESTIMAÇÃO | METODOLOGIA DE BOX EJENKINS

42




Case Serie 14 : Ajuste do modelo no R

2.ii. ESTIMAÇÃO | METODOLOGIA DE BOX EJENKINS

41

z test of coefficients:

```
      Estimate Std. Error z value      Pr(>|z|)
ma1 0.408389   0.020295  20.122 < 0.00000000000000022 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```



Case Serie 14 : Ajuste do modelo no R

2.ii. ESTIMAÇÃO | METODOLOGIA DE BOX EJENKINS

41

Equação do Modelo:

$$\hat{Y}_t = 0,4084 * \varepsilon_{t-1}$$



3. Exercícios para fixação



Exercícios para Fixação

3. EXERCÍCIOS | SERIES TEMPORAIS

39

Bases de dados:

- Série 13
- Série 22
- Série 33

- (a) Faça a análise exploratória da série, e comente seu comportamento.
- (b) Construa o gráfico descritivo da série.
- (c) Teste se a série é estacionária.
- (d) Apresente graficamente a função de autocorrelação (ACF) e a função de autocorrelação parcial (PACF) e discuta sobre a ordem a ser testada no modelo MA.
- (e) Ajuste um modelo Médias Móveis MA e avalie a significância dos parâmetros.
- (f) Apresente graficamente a função de autocorrelação (ACF) e a função de autocorrelação parcial (PACF) dos resíduos do modelo e discuta se a ordem do AR adotada está adequada.
- (g) Escreva a equação do modelo

Vamos fazer
juntos?

R Studio®



- Box, G. E. P. & Jenkins, G. M. (1976). *Time series analysis: Forecasting and control*. San Francisco: Holden-Day.
- Dickey, D. & Fuller, W. A. (1979). *Distribution of the estimates for autoregressive time series with a unit root*. Journal of the American Statistical Association, 74(2), 427-431.
- Morettin, P. A. & Toloi, C. M. de C. (2004). *Análise de séries temporais*. São Paulo: Edgard Blücher.
- Morettin, P. A. (2008). *Econometria financeira: um curso em séries temporais financeiras*. São Paulo: Edgard Blücher.

